

Fundamentos de Inteligencia Artificial Clásica: Técnicas, Métodos y Aplicaciones Antes de la IA Generativa

Luis Chamba-Eras

Editor

2026

Índice general

I	Introducción y Fundamentos	1
II	Aprendizaje Estadístico y Modelos de Clasificación	2
1.	Optimización de toma de decisiones por Q-learning	3
1.1.	Introducción	3
1.2.	Arquitecturas híbridas y multimodales	3
1.3.	Estabilización del aprendizaje en entornos de alta fidelidad	4
1.4.	Regulación dinámica de parámetros y control en tiempo real	4
1.5.	Fusión con algoritmos metaheurísticos y de enjambre	4
1.6.	Decisión multi-criterio bajo incertidumbre: marcos borrosos	5
1.7.	Sistemas distribuidos, federados y seguridad con Blockchain	5
1.8.	Aplicaciones y resultados en la optimización de procesos	5
1.8.1.	Combate no tripulado y navegación autónoma de UAVs	5
1.8.2.	Sistemas de transporte inteligente y redes vehiculares	6
1.8.3.	Salud y Cuidado	6
1.8.4.	Diseño estructural y logística portuaria	6
1.9.	Factores críticos en el entrenamiento y configuración	7
1.10.	Conclusiones	7

Parte I

Introducción y Fundamentos

Parte II

Aprendizaje Estadístico y Modelos de Clasificación

Capítulo 1

Optimización de la toma de decisiones autónoma mediante arquitecturas híbridas basadas en Q-learning en entornos dinámicos.

Autor: Darwin Ricardo Jimbo Jaramillo (darwin.jimbo@unl.edu.ec)

Técnica asignada: Aplicación de Q-learning en la toma de decisiones autónoma

1.1. Introducción

La toma de decisiones autónoma en entornos complejos e impredecibles requiere de mecanismos que trasciendan las capacidades de los sistemas de control tradicionales. [1] El Q-learning, como técnica fundamental del aprendizaje por refuerzo (RL), permite que un agente aprenda estrategias óptimas mediante la interacción continua con su entorno, estimando el valor de realizar una acción específica en un estado determinado para maximizar una recompensa a largo plazo. [2–4] En su forma clásica, este algoritmo construye una tabla bidimensional (Q-table) donde las filas representan los estados y las columnas las acciones, refinando sus valores mediante la regla de actualización:

$$Q(s, a) \leftarrow Q(s, a) + \alpha[r + \gamma \max_{a'} Q(s', a') - Q(s, a)] \quad (1.1)$$

Sin embargo, la aplicación de este enfoque en escenarios reales enfrenta la maldición de la dimensionalidad cuando los espacios de estados son masivos o continuos, lo que ha impulsado la integración de redes neuronales profundas para aproximar la función de valor Q, dando origen a las Deep Q-Networks (DQN). [2, 5, 6]

1.2. Arquitecturas híbridas y multimodales

La optimización de decisiones en entornos de alta incertidumbre, como el combate no tripulado o la navegación espacial, se beneficia de arquitecturas multimodales que fusionan datos heterogéneos. Estas estructuras emplean un codificador de características de doble rama: una red neuronal convolucional para extraer características espaciales de imágenes en tiempo real y una red neuronal recurrente para procesar secuencias temporales de datos de sensores, como velocidad de vuelo, ángulos de actitud y niveles de batería [7]. La concatenación de estas características:

$$\phi_t = f_{CNN}(I_t) \oplus f_{RNN}(S_t, E_t) \quad (1.2)$$

permite una representación del entorno mucho más robusta que los métodos de entrada única. [7] En el ámbito de la robótica espacial, los sistemas de navegación relativa para operaciones de acoplamiento autónomo integran soluciones de aprendizaje profundo para adaptarse a objetivos no cooperativos y entornos dinámicos, superando las limitaciones de los sistemas tradicionales de Guía, Navegación y Control (GNC). No obstante, la naturaleza de "caja negra" de estos sistemas plantea retos de interpretabilidad, lo que hace crítica la validación de resultados intermedios durante las fases de aproximación. [1]

1.3. Estabilización del aprendizaje en entornos de alta fidelidad

Para corregir problemas inherentes al Q-learning clásico, como el sesgo de sobreestimación, se han desarrollado arquitecturas como Double DQN (DDQN). [2, 3] Este enfoque mantiene dos redes independientes: una red de evaluación para seleccionar la acción óptima y una red objetivo para estimar el valor Q de dicha acción, lo que reduce las fluctuaciones de la política y mejora la convergencia en tareas de planificación de trayectorias. [2, 8] El uso de mecanismos de repetición de experiencia priorizada es fundamental para acelerar la convergencia, permitiendo que el modelo aprenda con mayor frecuencia de transiciones históricas que presentan un alto error de diferencia temporal (TD), es decir, aquellas de las que el agente tiene más dificultad para predecir el resultado. [2, 7, 9] En algoritmos avanzados como PERM-QN, se integra además una red de memoria que almacena trayectorias de alta utilidad, basadas en frecuencia de éxito y eficiencia energética, lo que permite al agente recuperar rutas eficientes en configuraciones ambientales similares y reducir la exploración redundante. [9]

1.4. Regulación dinámica de parámetros y control en tiempo real

En sistemas embebidos con restricciones estrictas de recursos como el CPU y memoria, el Q-learning tradicional resulta rígido e ineficiente. El Aprendizaje Q Adaptativo (AQL) introduce una regulación de parámetros dual que ajusta dinámicamente la tasa de aprendizaje (α) y el factor de descuento (γ) en función de la carga del sistema. Por ejemplo, ante una utilización de CPU superior al 80 por ciento, el factor de descuento se reduce (cerca de 0.3) para priorizar la estabilidad operativa y las recompensas inmediatas, mientras que en condiciones de baja carga se aumenta (cerca de 0.9) para enfatizar objetivos de cobertura a largo plazo. [5]

Complementariamente, el control mediante ventanas de tiempo deslizantes permite evaluar el rendimiento acumulado del sistema en intervalos específicos, lo que mitiga los sesgos de decisiones a corto plazo y facilita el ajuste de estrategias basado en el comportamiento reciente del entorno. Este enfoque ha demostrado mejorar la cobertura de pruebas de software en sistemas embebidos hasta en un 30 por ciento en comparación con estrategias de ventana fija. [5]

1.5. Fusión con algoritmos metaheurísticos y de enjambre

La hibridación del Q-learning con algoritmos de inteligencia de enjambre optimiza la búsqueda en espacios de soluciones complejos. En la planificación de rutas 3D para UAVs, el algoritmo PRM-QACO combina mapas de carreteras probabilísticos (PRM) para simplificar el espacio 3D con la optimización de colonias de hormigas (ACO). En esta arquitectura, un módulo de Q-learning actúa como controlador inteligente que ajusta dinámicamente el coeficiente de feromona de las hormigas, premiando o penalizando los resultados de búsqueda para evitar que el algoritmo caiga en óptimos locales. [5] De manera similar, la integración con la Optimización del Chacal Dorado (GJO) permite balancear la exploración y la explotación mediante la emulación

de comportamientos de caza colaborativa. Modelos híbridos como DQL-GJO han mostrado una eficiencia superior en el diseño de interfaces de usuario adaptativas para dispositivos médicos, logrando la convergencia en solo 45 épocas frente a las 70 requeridas por el DQL estándar. [10] En redes IoT, el algoritmo HHM-GJOA utiliza un mecanismo de memoria humana para cachear soluciones de alta aptitud, garantizando una selección de nodos de cabecera de clúster más segura y energéticamente eficiente. [11]

1.6. Decisión multi-criterio bajo incertidumbre: marcos borrosos

Para abordar la imprecisión en los juicios de expertos y la ambigüedad de los datos, se han desarrollado marcos híbridos que integran Q-learning con conjuntos borrosos complejos, como Complex q-Rung Orthopair Fuzzy Sets o Cq-ROFS. Estos modelos permiten representar información extensa en forma de términos de amplitud y fase, capturando tanto la incertidumbre como la periodicidad de los datos. [12]

El uso del método WASPAS (Weighted Aggregated Sum Product Assessment) dentro de estos marcos permite clasificar alternativas de decisión combinando las fortalezas de los enfoques de suma ponderada y producto ponderado. Al integrar operadores de agregación de Sugeno-Weber, el sistema puede manejar interrelaciones complejas entre criterios de decisión, proporcionando evaluaciones más equilibradas en escenarios de redes de comunicación modernas. [12]

1.7. Sistemas distribuidos, federados y seguridad con Blockchain

La optimización de decisiones en redes vehiculares y de IoT a gran escala se enfrenta al desafío de la privacidad de los datos. El Aprendizaje Federado (Federated Q-learning) permite que múltiples agentes aprendan de forma cooperativa rutas de datos óptimas sin necesidad de compartir sus datos brutos; los agentes entrenan modelos locales y solo envían actualizaciones de pesos a un servidor central para generar una política global. [3, 11]

Para garantizar la integridad y seguridad en estos entornos descentralizados, la integración de Blockchain y contratos inteligentes permite una gestión de acceso sensible a la confianza. [3, 13] El marco BDEQ, por ejemplo, utiliza Deep Q-learning para la selección adaptativa de nodos proxy, mientras que una capa de Blockchain asegura la gobernanza descentralizada y el cumplimiento de las políticas de acceso mediante contratos automatizados. [13]

1.8. Aplicaciones y resultados en la optimización de procesos

La versatilidad de estas arquitecturas híbridas basadas en Q-learning se manifiesta en diversos dominios técnicos:

1.8.1. Combate no tripulado y navegación autónoma de UAVs

En el ámbito del planeamiento de combate inteligente, la arquitectura MDRL-DQN (Deep Reinforcement Learning Multimodal) ha sido validada en escenarios de alta complejidad táctica. Los experimentos realizados en simulaciones de defensa dispersa a larga distancia y defensa concentrada a larga distancia arrojaron tasas de éxito de 89.6 % y 94.8 % respectivamente. Estas cifras superan significativamente a algoritmos como PPO, el cual completó las tareas en 865.3 s, mientras que el modelo basado en MDRL-DQN lo hizo en 720.8 s, lo que representa una mejora del 16.7 % en la eficiencia de ejecución. [7]

En misiones de penetración de enjambres, el modelo demostró una robustez crítica: en el escenario más exigente de defensa concentrada a corta distancia, el sistema aseguró la llegada de 4 UAVs al objetivo, mientras que métodos como A3C y DDPG solo lograron la llegada de uno, o incluso la desintegración total de la formación. Estos resultados se atribuyen a la capacidad

de la arquitectura para fusionar datos multimodales y priorizar objetivos mediante mecanismos de atención. [7]

Para la navegación en entornos interiores con obstáculos, la integración de redes LSTM y capas de ruido en un marco de Double DQN permitió mejoras drásticas en la seguridad de vuelo. En escenarios de pasillo largo, el algoritmo híbrido incrementó la recompensa acumulada promedio en un 22.88 % y la distancia de vuelo segura máxima en un 105.62 % en comparación con el Double DQN tradicional. En entornos más complejos, como salas de estar compactas, la distancia de vuelo segura aumentó en un 84.68 %, demostrando que la memoria temporal del LSTM es vital para percibir la ubicación de obstáculos en tiempo real. [2]

1.8.2. Sistemas de transporte inteligente y redes vehiculares

La optimización del tráfico urbano mediante Deep Q-Learning (DQL) ha mostrado resultados disruptivos en la reducción de la congestión. En intersecciones inteligentes, la implementación de un modelo DQL logró reducir la longitud de las colas en un 49 % e incrementar los incentivos de flujo por carril en un 9 %. Comparaciones con otros métodos de control de señales de tráfico indican que arquitecturas como DDQN con Experience Replay pueden reducir el retraso total del sistema hasta en un 82 %. [6]

En redes vehiculares de alta movilidad, el marco MH-DQN (Multi-Head Deep Q-Learning) para la formación de haces continuos permite mantener la alineación de señal bajo condiciones de desvanecimiento Rician. Los resultados muestran que, al aumentar el número de antenas de transmisión (de 8 a 64), el modelo MH-DQN supera drásticamente a los métodos de línea base en términos de tasa de error de bit (BER) y eficiencia espectral promedio (ASE). La estabilidad del aprendizaje se confirmó mediante el monitoreo de la pérdida por diferencia temporal (TD), la cual descendió de 1.6 a 0.6 en los primeros 10,000 pasos, manteniéndose constante sin divergencias. [14]

Para la seguridad en VANETs, el uso de Aprendizaje Federado asistido por Blockchain y Q-learning ha permitido gestionar el acceso de datos de forma segura con una latencia promedio de 864.425 ms para 100 vehículos, una cifra significativamente menor que los métodos centralizados que sufren de cuellos de botella por sobrecarga de comunicación. [3]

1.8.3. Salud y Cuidado

El Q-learning se ha aplicado con éxito en el diseño de interfaces de usuario adaptativas para dispositivos médicos portátiles. El modelo DQL-GJO, que optimiza los hiperparámetros mediante el algoritmo del Chacal Dorado, logró la convergencia en solo 45 épocas, frente a las 70 requeridas por el DQL estándar. Las pruebas de usabilidad revelaron que los usuarios completaron tareas un 32 % más rápido, con una reducción de errores del 45 % y un aumento de la satisfacción del usuario al 78 %. [10]

En el ámbito del soporte respiratorio, se desarrolló un concentrador de oxígeno inteligente que utiliza Q-learning para el control de flujo adaptativo. El sistema mantuvo un nivel medio de saturación de oxígeno (SpO_2) del 95.90 %, eliminando retrasos en la respuesta al alcanzar el objetivo terapéutico (0 pasos de retraso). El consumo total de energía durante la operación se situó en 225.2 julios, demostrando una alta eficiencia operativa en un dispositivo ultraportátil de solo 5.5 kg. [4]

1.8.4. Diseño estructural y logística portuaria

El aprendizaje Q profundo geométrico se ha aplicado a la selección de bordes independientes en estructuras de cubiertas reticuladas (RESS) para mejorar la estabilidad numérica. Los agentes entrenados mediante Boltzmann exploration generaron selecciones de bordes con números de

condicionamiento de matriz entre 10 y 20 veces mejores que los valores de referencia aleatorios, facilitando la exploración de espacios de diseño no convexos. [8]

En la optimización de patios de contenedores bajo criterios de baja emisión de carbono, el uso de algoritmos híper-heurísticos con mecanismos de Q-learning ha permitido:

- Reducir las emisiones de carbono de 214.87 kg a 125.28 kg.
- Disminuir las operaciones de re-manipulación de 27 a solo 2.
- Superar en estabilidad al algoritmo de optimización de ballenas (WOA), logrando soluciones óptimas de forma consistente en diversas iteraciones.

1.9. Factores críticos en el entrenamiento y configuración

El éxito de estas arquitecturas depende de un ajuste meticuloso de hiperparámetros. [6,7] El uso de una estrategia epsilon-greedy (ϵ -greedy) balancea la exploración y la explotación. [6,13] Un valor de ϵ que decrece linealmente, por ejemplo, de 1.0 a 0.01, asegura que el agente explore intensamente al inicio y se vuelva más determinista a medida que acumula experiencia. [7] Otros parámetros clave incluyen el factor de descuento (γ), que determina la importancia de las recompensas futuras, típicamente entre 0.75 y 0.99, y la tasa de aprendizaje (α), que controla la magnitud de las actualizaciones de la función de valor. [6,9,15]

En escenarios de búsqueda y rescate, la incorporación de funciones de recompensa con pesos dinámicos permite al robot priorizar la cobertura exhaustiva en las etapas iniciales y shifting el enfoque hacia la eficiencia energética y la minimización de la longitud de la ruta a medida que la batería disminuye. Este ajuste orquestado garantiza que el agente no solo complete la tarea, sino que mantenga la capacidad de regresar a su punto de origen de manera segura. [9]

1.10. Conclusiones

La evolución del Q-learning hacia arquitecturas híbridas que incorporan redes profundas, lógica difusa, metaheurísticas y aprendizaje federado representa la vanguardia de la inteligencia artificial clásica aplicada a problemas complejos de decisión autónoma, proporcionando soluciones robustas, adaptables y eficientes en una amplia gama de entornos dinámicos. [5,7,11,12,15,16]

La implementación de modelos multimodales, como el MDRL-DQN, demuestra una capacidad crítica para procesar datos heterogéneos, logrando tasas de éxito de hasta un 94.8% en misiones de combate no tripulado. Estos sistemas no solo mejoran la precisión, sino también la eficiencia temporal, completando tareas hasta un 16.7% más rápido que algoritmos de política de gradiente como el PPO. [7] La fusión de mapas probabilísticos con optimización de colonia de hormigas y controladores Q-learning optimiza la navegación 3D al reducir las variaciones erráticas en la ruta y evitar óptimos locales mediante el ajuste dinámico de feromonas. [16]

Referencias

- [1] S. Khalil, Z. Wang, and N. Aouf, “Hybrid deep learning based monocular pose estimation for autonomous space docking operations,” *Acta Astronautica*, vol. 238, pp. 612–629, 1 2026.
- [2] R. Yu, Q. Li, J. Ji, T. Wu, J. Mao, S. Liu, and Z. Sun, “Improved double dqn with deep reinforcement learning for uav indoor autonomous obstacle avoidance,” *Scientific Reports*, vol. 15, pp. 1–17, 12 2025.
- [3] H. A. Ahmed, H. M. Jasim, A. N. Gatea, A. A. A. Al-Asadi, and H. A. A. Al-Asadi, “A secure and efficient blockchain enabled federated q-learning model for vehicular ad-hoc networks,” *Scientific Reports*, vol. 14, pp. 1–23, 12 2024.
- [4] V. Sivalingam, J. Jayaraj, S. H. J. Paul, and G. Yadav, “Intelligent oxygen delivery: a portable concentrator combining closed-loop automation, psa, and q-learning for optimized performance,” *Discover Applied Sciences*, vol. 7, pp. 1–37, 11 2025.
- [5] Y. Niu and S. S. Chai, “Design and optimization of a test case generation algorithm for real-time embedded systems based on adaptive q-learning,” *Automated Software Engineering*, vol. 33, pp. 1–37, 12 2026.
- [6] S. M. R. Swapno, S. N. Nobel, P. Meena, V. P. Meena, A. T. Azar, Z. Haider, and M. Tounsi, “A reinforcement learning approach for reducing traffic congestion using deep q learning,” *Scientific Reports*, vol. 14, pp. 1–20, 12 2024.
- [7] X. Jianhong and L. Gongqian, “Enhanced q learning and deep reinforcement learning for unmanned combat intelligence planning in adversarial environments,” *Scientific Reports*, vol. 15, pp. 1–15, 12 2025.
- [8] K. M. Tam, R. M. Avelino, D. Kudenko, T. V. Mele, and P. Block, “Well-conditioned ai-assisted sub-matrix selection for numerically stable constrained form-finding of reticulated shells using geometric deep q-learning,” *Meccanica*, vol. 60, pp. 525–556, 3 2025.
- [9] Y. Xue, C. K. Tan, and W. P. Wong, “An energy aware q-learning framework for comprehensive coverage path planning in unknown complex environments,” *Scientific Reports*, vol. 15, pp. 1–18, 12 2025.
- [10] M. Jiang, J. Huang, and L. Wang, “Adaptive user interfaces for wearable medical devices using deep q-learning and golden jackal optimization,” *Scientific Reports*, vol. 15, pp. 1–13, 12 2025.
- [11] K. Bala, D. Venu, B. P. Dudi, V. Nirmala, K. A. Kumar, and M. Manohara, “Federated deep reinforcement q-learning for secure and energy-efficient data routing in internet of things networks,” *Peer-to-Peer Networking and Applications*, vol. 19, pp. 1–18, 5 2026.
- [12] H. Zeng and Y. Zhang, “Hybrid machine learning techniques for knowledge extraction in communication networks and advanced decision based complex q-rung orthopair fuzzy frameworks,” *Scientific Reports*, vol. 15, pp. 1–17, 12 2025.

- [13] M. Bayat, M. A. J. Jamali, M. Abbasi, B. Anari, and S. Akbarpour, “Enhancing secure iot data sharing through dynamic q-learning and blockchain at the edge,” *Scientific Reports*, vol. 15, pp. 1–28, 12 2025.
- [14] N. H. Trung, N. T. Anh, and F. Liu, “Multi-head deep q-learning for continuous beamforming with selective mc-cdma operation in v2x highway communications,” *Scientific Reports*, vol. 15, pp. 1–24, 12 2025.
- [15] L. Chen, J. Lin, and S. Xu, “A study on container storage optimization in yards based on a hyper-heuristic algorithm with a q-learning mechanism,” *International Journal of Computational Intelligence Systems*, vol. 18, pp. 1–24, 12 2025.
- [16] S. Liu, Y. Cui, Y. Yu, and W. Hu, “A q-learning-based hybrid search algorithm integrating prm and aco for 3d uav path planning,” *Scientific Reports*, vol. 16, pp. 1–20, 12 2026.